

**ANALIZA ȘI PROGNOZAREA PREȚURILOR AUTOMOBILELOR
SECOND-HAND DIN MOLDOVA PRIN METODE DE ÎNVĂȚARE
AUTOMATĂ ȘI EVALUAREA INCERTITUDINII PROGNOZELOR**

**АНАЛИЗ И ПРОГНОЗИРОВАНИЕ ЦЕН НА РЫНКЕ ПОДДЕРЖАННЫХ
АВТОМОБИЛЕЙ МОЛДОВЫ МЕТОДАМИ МАШИННОГО
ОБУЧЕНИЯ И ОЦЕНКОЙ НЕОПРЕДЕЛЁННОСТИ ПРОГНОЗОВ**

Mihail CULIȘ

¹ *Departamentul Informatică și Ingineria Sistemelor, grupa SD-251M, Facultatea FCIM,
Universitatea Tehnică a Moldovei, Chișinău, Moldova*

Autorul corespondent: Culiș Mihail, e-mail: yamihail1034@gmail.com

Îndrumătorul/coordonatorul științific: Viorel Munteanu, conf. univ., dr.

Резюме

Работа посвящена прогнозированию цен подержанных легковых автомобилей по объявлениям интернет-площадки 999.md. Автоматизированно собрано 30 013 объявлений; после очистки (удаление дубликатов, новых автомобилей и некорректных значений) осталось 26 468 записей, описанных 20 признаками. Сопоставлены четыре модели: линейная регрессия (базовый уровень), Random Forest, XGBoost и HistGradientBoosting; качество оценено на отложенной выборке и 5-кратной кросс-валидацией.

Две лучшие модели, XGBoost и HistGradientBoosting, практически неразличимы по качеству: XGBoost лучше по MAE (2 480 €) и MAPE (16,3%), HistGradientBoosting — по RMSE и R^2 (0,900 против 0,898). Обе точнее линейной регрессии на 10–11% по MAE и на 13–14% по RMSE. Парный критерий Уилкоксона подтвердил превосходство каждой из трёх ансамблевых моделей над линейной ($p < 10^{-9}$), но не выявил надёжных различий между самими ансамблями. По результатам permutation importance и SHAP главным фактором цены является возраст автомобиля, далее следуют объём двигателя, тип привода, коробка передач и марка.

Анализ смещений показал систематическое завышение прогнозов для дешёвых автомобилей (в среднем на 13,9%) и занижение для дорогих (в среднем на 2 214 €). Метод split conformal prediction дал интервалы с фактическим покрытием 80,5% и 90,2% при номинальных 80% и 90%. Работа показывает, какие факторы определяют цену на местном рынке, где модели ошибаются сильнее всего и насколько надёжна каждая оценка.

Ключевые слова: цены подержанных автомобилей, машинное обучение, градиентный бустинг, SHAP, смещение модели, conformal prediction, 999.md.

Введение

Рынок подержанных автомобилей отличается большим разнообразием предложений, различиями в техническом состоянии и значительным разбросом цен. Покупателю и продавцу трудно определить справедливую стоимость конкретного автомобиля по набору его характеристик: возрасту, пробегу, марке, объёму двигателя, типу топлива и коробки передач. Для Республики Молдова, где значительная часть автомобилей ввозится из-за рубежа, эта задача усложняется разнообразием стран происхождения и статусов растаможки.

Методы машинного обучения позволяют выявлять нелинейные зависимости между характеристиками автомобиля и ценой. В ряде работ для оценки стоимости подержанных автомобилей по объявлениям региональных интернет-площадок применялись линейные модели, деревья решений, ансамбли деревьев, метод опорных векторов и нейронные сети [1, 2]. Однако для академического исследования недостаточно обучить одну модель. Необходимо сравнить несколько алгоритмов на одних и тех же данных, статистически проверить различия между ними, выяснить, какие признаки определяют прогноз, найти систематические ошибки и количественно оценить надёжность отдельного прогноза. В доступной автору литературе эти задачи редко рассматриваются вместе, а для рынка Молдовы подобных исследований найти не удалось.

Цель работы — разработать и оценить модели машинного обучения для прогнозирования цен подержанных автомобилей на основе объявлений 999.md, определить факторы, влияющие на цену, и исследовать неопределённость прогнозов. Для достижения цели поставлены следующие **задачи**: (1) собрать и очистить данные; (2) обучить и сравнить модели по единым метрикам; (3) статистически проверить различия между моделями; (4) определить значимость признаков методами permutation importance и SHAP; (5) исследовать ошибки и смещения прогнозов по сегментам рынка; (6) построить прогнозные интервалы и проверить их покрытие.

Рабочая гипотеза: ансамблевые методы (Random Forest, XGBoost) обеспечивают более высокую точность прогнозирования цен, чем линейная регрессия, при этом качество прогноза зависит от характеристик автомобиля и сегмента рынка. В ходе работы метод опорных векторов (SVR), первоначально включённый в план, был заменён на HistGradientBoosting: обучение SVR на данном объёме (около 17 тысяч объектов и сотни

признаков после кодирования) оказалось неоправданно долгим, так как вычислительная сложность метода растёт не менее чем квадратично с числом объектов.

1. Данные

1.1 Источник и сбор данных

Данные получены с интернет-площадки объявлений 999.md [3], раздела «Autoturisme». Объявления собирались автоматизированно в октябре 2026 г. через запросы к программному интерфейсу, который использует веб-клиент сайта, с умеренной частотой запросов и паузами между ними. Выбирались объявления в порядке убывания даты обновления; на момент сбора в разделе было около 97 тысяч объявлений, в выборку вошли 30 013 самых свежих. Персональные данные продавцов (имена, телефоны) не собирались. Цены, указанные не в евро, пересчитывались в евро по фиксированному курсу; пробег, заданный в милях, переводился в километры.

Для каждого объявления получены цена, год выпуска, пробег, тип топлива, тип коробки передач, тип продавца (частное лицо или автодилер), состояние, регион, а также марка, модель, поколение, тип кузова, привод, объём двигателя, мощность, число мест и дверей, цвет, статус растаможки, регион происхождения и наличие автомобиля. Целевая переменная — цена в объявлении в евро. Важно, что это **цена предложения**, а не цена фактической сделки: итоговая цена после торга, как правило, ниже.

1.2 Очистка данных

Очистка выполнялась последовательно (табл. 1). Удалялись повторы объявлений (по адресу и по совпадению марки, модели, года, пробега, цены и региона), новые автомобили (состояние «новый», пробег около нуля), записи без обязательных полей (цена, год, пробег, марка) и записи с нереалистичными значениями (цена вне диапазона 500–150 000 €, год ранее 1990, пробег вне диапазона 1 000–600 000 км, объём двигателя вне диапазона 0,6–7 л). В 1 630 объявлениях пробег был указан в тысячах (например, 322 вместо 322 000 км); для автомобилей старше двух лет такие значения умножались на 1 000. Редкие модели (менее 15 объявлений) объединялись в категорию «прочие», редкие марки (менее 10) — аналогично.

Таблица 1

Этапы очистки данных

Этап	Удалено	Осталось
Собрано объявлений	—	30 013
Удаление дубликатов	1 923	28 090
Исключение новых автомобилей	717	27 373
Исключение записей без обязательных полей	458	26 915
Исключение нереалистичных значений	447	26 468

1.3 Признаки

Итоговая выборка содержит 26 468 объявлений и 20 признаков: 6 числовых и 14 категориальных (табл. 2). Возраст автомобиля рассчитан как разность между 2026 годом и годом выпуска. Мощность двигателя указана не во всех объявлениях; пропуски заполнялись медианой, а для модели добавлялся индикатор пропуска.

Таблица 2

Признаки, использованные в моделях

Тип	Признаки
Числовые (6)	возраст, пробег, объём двигателя, мощность, число мест, число дверей
Категориальные (14)	марка, модель, поколение, тип топлива, коробка передач, тип кузова, привод, регион, тип продавца, состояние, статус растаможки, регион происхождения, наличие, цвет
Целевая переменная	цена в объявлении, € (в моделях используется её натуральный логарифм)

1.4 Описательная статистика

Распределение цен имеет выраженную правостороннюю асимметрию (рис. 1): медиана составляет 13 990 €, межквартильный размах — от 8 000 до 22 499 €, а 90% объявлений укладываются в интервал от 2 800 до 47 640 €; дороже 60 000 € предлагается лишь 2,5% автомобилей. Эта асимметрия — основание для логарифмирования цены: в логарифмической шкале ошибки пропорциональны цене, а распределение остатков ближе к симметричному.




Рисунок 1. Распределение цен в объявлениях (N = 26 468)

Структура выборки отражает особенности местного рынка. Наиболее представлены BMW (3 302 объявления; медианная цена 22 500 €), Mercedes (2 529; 20 499 €), Volkswagen (1 827; 9 900 €), Toyota (1 821; 12 000 €), Ford (1 812; 9 200 €) и Renault (1 783; 9 300 €). Преобладают автомобили с автоматической коробкой (19 089 объявлений; медианная цена 17 500 € против 6 000 € у механики) и дизельные двигатели (11 657), но заметна и доля гибридов: 3 028 объявлений о подзаряжаемых гибридах на бензине и 2 205 о гибридах.

Медианная цена по возрасту (рис. 2) отражает типичную динамику обесценивания: от 41 925 € у автомобилей текущего года до 30 400 € через год, 21 698 € через пять лет, 12 000 € через десять и 4 699 € через двадцать лет. Следует учитывать, что кривые построены по срезу рынка на одну дату, а не по наблюдению за одними и теми же автомобилями во времени.




Рисунок 2. Медианная цена в объявлениях в зависимости от возраста автомобиля (точки с числом объявлений менее 8 не показаны)

2. Методология исследования

2.1 Подготовка признаков и разбиение данных

Категориальные признаки преобразовывались в бинарные индикаторы (one-hot); категории, встречающиеся менее пяти раз, объединялись. Числовые пропуски заполнялись медианой с добавлением индикатора пропуска; для линейной модели числовые признаки дополнительно стандартизировались. Данные разделены случайным образом (фиксированное начальное значение генератора случайных чисел для воспроизводимости): 20% (5 294 объявления) выделены для итоговой проверки, из оставшихся 20% (4 235) — для калибровки интервалов неопределённости, остальные 16 939 использованы для обучения.

2.2 Модели

Линейная регрессия на закодированных признаках служит базовым уровнем. Random Forest [4] — ансамбль из 300 решающих деревьев, обученных на бутстрэп-выборках. XGBoost [5] — градиентный бустинг, в котором деревья строятся последовательно и исправляют ошибки предыдущих. HistGradientBoosting [6, 7] — реализация градиентного бустинга на гистограммах признаков из библиотеки scikit-learn [7]. Гиперпараметры ансамблевых моделей подбирались случайным поиском по 12 комбинациям с 3-кратной кросс-валидацией на обучающей части (критерий — MAE).

2.3 Метрики качества

Качество оценивалось на отложенной выборке по четырём метрикам, рассчитанным в евро после обратного преобразования прогноза из логарифмической шкалы: средняя абсолютная ошибка (MAE), среднеквадратичная ошибка (RMSE), коэффициент детерминации R^2 и средняя абсолютная процентная ошибка (MAPE). Основным критерием выбора модели для дальнейшего анализа принята MAE: по этой метрике подбирались гиперпараметры, а ошибка в евро легко интерпретируется. Коэффициент детерминации R^2 (доля объяснённой дисперсии) и RMSE дают единый порядок моделей, но сильнее реагируют на редкие крупные ошибки, то есть на дорогие автомобили, поэтому результаты приводятся по всем четырём метрикам. Дополнительно выполнена 5-кратная кросс-валидация по всему набору данных. Поскольку гиперпараметры подбирались на части этих же данных, кросс-валидация служит проверкой устойчивости результатов, а не независимой оценкой качества.

2.4 Статистическая проверка различий между моделями

Для проверки гипотезы сопоставлялись абсолютные ошибки двух моделей на одних и тех же 5 294 объектах отложенной выборки односторонним парным критерием Уилкоксона [8] (альтернатива: ошибки модели A меньше, чем модели B). Выполнено шесть сравнений, поэтому с поправкой Бонферрони порог значимости составляет $0,05/6 \approx 0,008$.

2.5 Интерпретация моделей

Важность признаков оценивалась двумя способами. Permutation importance [9] — снижение R^2 (в логарифмической шкале цены) при случайном перемешивании значений признака; рассчитывалось для исходных признаков и для каждой модели. SHAP [10] — вклад признаков в каждый отдельный прогноз на основе значений Шепли; рассчитывался для XGBoost (лучшей по MAE) на 1 000 объектах отложенной выборки; SHAP-расчёт для деревьев доступен для этой модели, а R^2 и RMSE у неё практически совпадают с HistGradientBoosting. Метод LIME [11] также применялся к двум автомобилям, однако его объяснения оказались малоинформативными: на матрице с one-hot-кодированием они сводились к индикаторам отдельных поколений моделей. Поэтому в анализе используются SHAP и permutation importance.

2.6 Анализ ошибок и смещений

Ошибка прогноза определялась как разность прогноза и фактической цены, поэтому положительное смещение означает завышение цены моделью. Смещение рассчитывалось как средняя ошибка со знаком в евро и в процентах от фактической цены по сегментам: квартилям цены, группам возраста, десяти наиболее частым маркам и типам топлива.

2.7 Оценка неопределённости

Для построения прогнозных интервалов использован метод split conformal prediction [12–14]. На калибровочной выборке вычислялись абсолютные остатки в логарифмической шкале, затем находился их эмпирический квантиль уровня $[(n+1)(1-\alpha)]/n$, где n — размер калибровочной выборки, а α — допустимая доля ошибок. Интервал для нового объекта строился как $[\hat{y} \cdot e^{(-q)}, \hat{y} \cdot e^{(q)}]$, где $\hat{y}$ — прогноз. Метод не требует предположений о распределении остатков и гарантирует покрытие не ниже $1-\alpha$ при условии, что данные взаимозаменяемы. Покрытие проверялось на отложенной выборке.

Результаты и обсуждение

1. Сравнение моделей

Результаты сравнения приведены в табл. 3 и на рис. 3. Все ансамблевые модели превосходят линейную по всем метрикам. Наименьшую среднюю абсолютную ошибку показал XGBoost (2 480 €, MAPE 16,3%), что на 10,5% меньше ошибки линейной регрессии (2 771 €). Если ранжировать модели по R^2 , первое место занимает HistGradientBoosting, но разница с XGBoost составляет всего 0,002 (при кросс-валидации 0,900 и 0,899), поэтому на практике модели равноценны. Наименьшее значение RMSE (4 943 €) и наибольший R^2 (0,900) у HistGradientBoosting; RMSE ниже, чем у линейной модели, на 13,9%. Random Forest уступает бустингам (MAE 2 530 €, R^2 0,887), но остаётся заметно лучше линейной регрессии. Результаты кросс-валидации близки к результатам на отложенной выборке (MAE ансамблей — от 2 437 до 2 453 €, у линейной модели 2 739 €), что говорит об устойчивости оценок и отсутствии выраженного переобучения.

Таблица 3

Качество моделей на отложенной выборке и при кросс-валидации

Модель	MAE, €	RMSE, €	R ²	MAPE, %	CV MAE, €	CV R ²
Линейная регрессия	2 771	5 739	0,865	17,8	2 739	0,865
Random Forest	2 530	5 262	0,887	17,0	2 437	0,891
HistGradientBoosting	2 506	4 943	0,900	16,4	2 443	0,900
XGBoost	2 480	5 004	0,898	16,3	2 453	0,899




Рисунок 3. Сравнение моделей на отложенной выборке (LR — линейная регрессия, RF — Random Forest, HGB — HistGradientBoosting, XGB — XGBoost)

Относительная ошибка остаётся значительной: MAPE составляет 16–18%. Диаграмма «прогноз — факт» (рис. 4) показывает, что основная масса точек лежит вдоль диагонали, однако для автомобилей дороже 60 000 € разброс заметно возрастает, а наиболее дорогие предложения модель в основном занижает.




Рисунок 4. Прогноз XGBoost и фактическая цена на отложенной выборке

2. Проверка гипотезы

Результаты парных сравнений приведены в табл. 4. Каждая из трёх ансамблевых моделей статистически значимо точнее линейной регрессии ($p < 10^{-9}$ во всех случаях, в том числе с поправкой Бонферрони): первая часть гипотезы подтверждается. Между собой ансамбли различаются слабо. XGBoost не точнее Random Forest ($p = 0,40$), HistGradientBoosting также не превосходит Random Forest ($p = 0,96$), а различие между XGBoost и HistGradientBoosting ($p = 0,046$) не проходит порог с учётом поправки на множественные сравнения. Показательно, что медианная абсолютная ошибка у Random Forest (1 319 €) даже ниже, чем у бустингов (около 1 361 €), тогда как средние ошибки (MAE, RMSE) у бустингов меньше. Это означает, что для типичных автомобилей Random Forest не хуже, а преимущество бустинга сосредоточено в более редких крупных ошибках, то есть на дорогих автомобилях.

Таблица 4

Парные сравнения абсолютных ошибок (критерий Уилкоксона, H_1 : ошибки A < ошибки B)

Модель A	Модель B	Медиана ошибки A, €	Медиана ошибки B, €	p-значение
Random Forest	Линейная регрессия	1 319	1 468	$< 10^{-9}$
XGBoost	Линейная регрессия	1 361	1 468	$< 10^{-9}$
HistGradientBoosting	Линейная регрессия	1 361	1 468	$< 10^{-9}$
XGBoost	Random Forest	1 361	1 319	0,401
HistGradientBoosting	Random Forest	1 361	1 319	0,959
XGBoost	HistGradientBoosting	1 361	1 361	0,046

Вторая часть гипотезы — о зависимости качества от сегмента рынка — подтверждается анализом ошибок (подраздел 4 данного раздела).

3. Факторы, определяющие цену

По результатам permutation importance (рис. 5) для XGBoost абсолютно доминирует возраст автомобиля: его перемешивание снижает R^2 на 0,78. Далее следуют объём двигателя (0,12), марка (0,04), привод (0,04), пробег (0,03), коробка передач и статус растаможки. Для линейной регрессии картина иная: наибольший вклад после возраста (0,60) вносят марка (0,41), поколение (0,28) и модель (0,28). Различие объясняется тем, что линейная модель вынуждена передавать различия между классами автомобилей через категориальные признаки, тогда как деревья используют объём двигателя, привод и коробку передач, которые частично кодируют ту же информацию. Кроме того, permutation importance занижает важность взаимосвязанных признаков.




Рисунок 5. Важность признаков по permutation importance (снижение R^2 в логарифмической шкале цены)

SHAP-анализ модели XGBoost (рис. 6) согласуется с этими результатами. Среднее абсолютное значение вклада в логарифмической шкале цены наибольшее у возраста (0,44), затем у объёма двигателя (0,15), переднего привода (0,14), механической коробки передач (0,06), пробега (0,05) и мощности (0,03). Направления эффектов соответствуют ожиданиям: увеличение возраста и пробега снижает прогнозируемую цену, больший объём двигателя и большая мощность повышают её. Передний привод и механическая коробка передач снижают цену, что связано с принадлежностью таких автомобилей к более дешёвым классам. Заметно, что вклад пробега существенно меньше вклада возраста; возможные причины — сильная корреляция пробега с возрастом и неточности в указании пробега продавцами.




Рисунок 6. SHAP-вклады признаков в прогноз XGBoost (*numage* — *возраст*, *numengine_l* — *объём двигателя*, *catdrive_Din Față* — *передний привод*, *catgearbox_Mecanică* — *механическая коробка*, *nummileage* — *пробег*, *numpower* — *мощность*)

4. Ошибки и смещения прогнозов

Ошибки модели сильно зависят от сегмента рынка (табл. 5, рис. 7). Абсолютная ошибка растёт от 1 025 € в самом дешёвом квартиле до 5 370 € в самом дорогом. При этом в процентах картина обратная: в дешёвом сегменте модель в среднем **завышает** цену на 13,9% (на 421 €), в самом дорогом — **занижает** на 4,5% (на 2 214 €). По возрасту наибольшая абсолютная ошибка приходится на автомобили до 3 лет (5 112 €), наименьшая — на автомобили старше 20 лет (936 €), однако для самых старых автомобилей среднее процентное завышение максимально (9,9%): модель плохо различает очень дешёвые предложения.

Таблица 5

Ошибки и смещение прогнозов XGBoost по сегментам (смещение = прогноз – факт)

Сегмент	Объектов	MAE, €	Смещение, €	Смещение, %
Цена: Q1 (дешёвые)	1 331	1 025	421	+13,9%
Цена: Q2	1 319	1 484	211	+1,9%
Цена: Q3	1 325	2 056	132	+0,8%
Цена: Q4 (дорогие)	1 319	5 370	-2 214	-4,5%
Возраст: 0-3 лет	578	5 112	-812	+2,4%
Возраст: 4-7 лет	1 662	2 864	-228	+2,7%
Возраст: 8-12 лет	1 674	2 038	-216	+3,0%
Возраст: 13-20 лет	958	1 677	-667	+1,2%
Возраст: 20+ лет	422	936	-140	+9,9%




Рисунок 7. Абсолютная ошибка и среднее смещение по ценовым сегментам и группам возраста

Различие знаков смещения в евро и в процентах объясняется тем, что средняя процентная ошибка определяется в основном дешёвыми автомобилями (где небольшая абсолютная ошибка даёт большую относительную), а средняя ошибка в евро — дорогими. По маркам наибольшее занижение в евро наблюдается у премиальных автомобилей: Mercedes (–907 €), Audi (–587 €), BMW (–292 €), а также Toyota (–479 €) и Volvo (–468 €); у Ford (+203 €) и Renault (+62 €) прогнозы в среднем слегка завышены. Среди типов топлива заметно занижение для электромобилей (–1 376 €, 161 объект) и подзаряжаемых гибридов

на дизеле (–3 184 €, 25 объектов), а также завышение для мягких гибридов на бензине (+2 959 €, 39 объектов). Выводы по этим группам ненадёжны из-за малого числа наблюдений.

5. Оценка неопределённости

Конформные интервалы показали фактическое покрытие, близкое к номинальному (табл. 6): 80,5% при уровне 80% и 90,2% при уровне 90%. Средняя ширина 80%-интервала составляет 8 308 €, что соответствует примерно 47% от прогнозируемой цены (то есть около $\pm 24\%$); для 90%-интервала — 11 794 € и 67% соответственно.

Таблица 6

Покрывание и ширина конформных интервалов на отложенной выборке

Номинальный уровень	Фактическое покрытие	Средняя ширина, €	Медианная ширина, % от прогноза
80%	80,5%	8 308	47%
90%	90,2%	11 794	67%

Следует учитывать особенность метода: поскольку интервал строится в логарифмической шкале с единым квантилем, его относительная ширина одинакова для всех автомобилей (в абсолютных единицах он шире для дорогих). Поэтому интервалы не учитывают того, что относительная точность различается по сегментам (см. подраздел 4): для одних групп они могут быть избыточно широкими, для других — недостаточными. Покрывание по отдельным сегментам не проверялось.

6. Обсуждение и ограничения

Полученные результаты согласуются с общим представлением о том, что для табличных данных ансамбли деревьев надёжнее линейных моделей [15]. Вместе с тем выигрыш оказался умеренным (около 10% по MAE): линейная модель на логарифме цены с one-hot-кодированием марок, моделей и поколений является сильным базовым уровнем, а основная доля дисперсии цены объясняется возрастом. Для практики важно, что ошибка в 2 500 € при медианной цене 13 990 € соответствует примерно 18% от типичной цены; 80%-й интервал шириной около $\pm 24\%$ показывает, что точная оценка по одним лишь характеристикам из объявления невозможна.

Ограничения исследования. (1) Целевая переменная — цена предложения, а не сделки. (2) Данные получены на одну дату и включают только самые свежие объявления, поэтому кривые обесценивания описывают срез рынка, а не динамику цен конкретных

автомобилей, а в выборке могут быть смещены доли дилеров и типов автомобилей. (3) Остаются неучтёнными факторы, сильно влияющие на цену: комплектация, техническое состояние, история аварий, качество фотографий и текст описания. (4) Хотя дубликаты объявлений удалялись, похожие объявления одного продавца могут попадать и в обучающую, и в проверочную выборки, что способно слегка завышать оценки качества. (5) Пересчёт цен в других валютах выполнялся по фиксированному курсу. (6) Конформные интервалы не адаптируются к неоднородности точности по сегментам. (7) Метод SVR из исходного плана в сравнение не вошёл.

Направления дальнейшей работы: использование текстовых описаний объявлений; повторные сборы данных для изучения динамики цен; адаптивные интервалы (конформная квантильная регрессия); отдельные модели для ценовых сегментов и премиальных марок, где ошибки максимальны; проверка других ансамблевых реализаций (LightGBM, CatBoost).

Выводы

1. Собрана и очищена выборка из 26 468 объявлений о продаже подержанных легковых автомобилей на 999.md с 20 признаками.
2. Все три ансамблевые модели статистически значимо точнее линейной регрессии ($p < 10^{-9}$). Лучшей по MAE и MAPE оказалась модель XGBoost (MAE 2 480 €, MAPE 16,3%), лучшей по RMSE и R^2 — HistGradientBoosting (R^2 0,900; у XGBoost 0,898); различия между ансамблями малы и в большинстве сравнений статистически не подтверждены.
3. Главным фактором цены является возраст автомобиля; существенный вклад вносят также объём двигателя, тип привода, коробка передач и марка. Этот вывод согласуется между permutation importance и SHAP.
4. Качество прогноза зависит от сегмента рынка: модель завышает цены дешёвых автомобилей (в среднем на 13,9%) и занижает цены дорогих (в среднем на 2 214 €), а абсолютная ошибка в верхнем ценовом квантиле в пять раз больше, чем в нижнем.
5. Метод split conformal prediction дал интервалы с фактическим покрытием 80,5% и 90,2% при номинальных 80% и 90%; их ширина (около $\pm 24\%$ и $\pm 33\%$ от прогноза) отражает существенную неопределённость оценки по доступным в объявлении характеристикам.

Библиография

- [1] S. Pudaruth, “Predicting the price of used cars using machine learning techniques,” *Int. J. Inf. Comput. Technol.*, vol. 4, no. 7, pp. 753–764, 2014.
- [2] E. Gegic, B. Isakovic, D. Keco, Z. Masetic, and J. Kevric, “Car price prediction using machine learning techniques,” *TEM J.*, vol. 8, no. 1, pp. 113–118, 2019.
- [3] 999.md, “Autoturisme: anunțuri de vânzare.” [Online]. Available: <https://999.md/ro/list/transport/cars>. [Accessed: 07-Oct-2026].
- [4] L. Breiman, “Random forests,” *Mach. Learn.*, vol. 45, no. 1, pp. 5–32, 2001.
- [5] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discov. Data Min.*, 2016, pp. 785–794.
- [6] G. Ke et al., “LightGBM: A highly efficient gradient boosting decision tree,” in *Adv. Neural Inf. Process. Syst.* 30, 2017, pp. 3146–3154.
- [7] F. Pedregosa et al., “Scikit-learn: Machine learning in Python,” *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.
- [8] F. Wilcoxon, “Individual comparisons by ranking methods,” *Biometrics Bull.*, vol. 1, no. 6, pp. 80–83, 1945.
- [9] A. Fisher, C. Rudin, and F. Dominici, “All models are wrong, but many are useful: Learning a variable’s importance by studying an entire class of prediction models simultaneously,” *J. Mach. Learn. Res.*, vol. 20, no. 177, pp. 1–81, 2019.
- [10] S. M. Lundberg and S.-I. Lee, “A unified approach to interpreting model predictions,” in *Adv. Neural Inf. Process. Syst.* 30, 2017, pp. 4765–4774.
- [11] M. T. Ribeiro, S. Singh, and C. Guestrin, “‘Why should I trust you?’ Explaining the predictions of any classifier,” in *Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discov. Data Min.*, 2016, pp. 1135–1144.
- [12] V. Vovk, A. Gammerman, and G. Shafer, *Algorithmic Learning in a Random World*. New York, NY, USA: Springer, 2005.
- [13] J. Lei, M. G’Sell, A. Rinaldo, R. J. Tibshirani, and L. Wasserman, “Distribution-free predictive inference for regression,” *J. Amer. Statist. Assoc.*, vol. 113, no. 523, pp. 1094–1111, 2018.
- [14] A. N. Angelopoulos and S. Bates, “A gentle introduction to conformal prediction and distribution-free uncertainty quantification,” *arXiv:2107.07511*, 2021.
- [15] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*, 2nd ed. New York, NY, USA: Springer, 2009.